

## Projet : Deep Food

Nous utilisons le GPU pour bénéficier de l'entraînement en précision mixte.

```
!nvidia-smi -L
```

```
GPU 0: NVIDIA GeForce RTX 2060 (UUID: GPU-a2b4317d-436b-2cc1-0fe3-ac16673637a5)
```

Obtenir des fonctions d'assistance.

```
# Importer une série de fonctions d'assistance pour le notebook
from helper_functions import create_tensorboard_callback,
plot_loss_curves, compare_histories
```

Nous utilisons TensorFlow datasets pour télécharger les données.

- Si vous voulez un aperçu, lisez le guide : <https://www.tensorflow.org/datasets/overview?hl=fr>
- Documentation de food101 sur TensorFlow :  
[https://data.vision.ee.ethz.ch/cvl/datasets\\_extra/food-101/](https://data.vision.ee.ethz.ch/cvl/datasets_extra/food-101/)

```
# Obtenir les datasets de TensorFlow
import tensorflow_datasets as tfds

# Lister tous les datasets disponibles
tfds_list = tfds.list_builders()
tfds_list

['abstract_reasoning',
 'accentdb',
 'aeslc',
 'aflw2k3d',
 'ag_news_subset',
 'ai2_arc',
 'ai2_arc_with_ir',
 'aloha_mobile',
 'amazon_us_reviews',
 'anli',
 'answer_equivalence',
 'arc',
 'asqa',
 'asset',
 'assin2',
 'asu_table_top_converted_externally_to_rlds',
 'austin_buds_dataset_converted_externally_to_rlds',
 'austin_sailor_dataset_converted_externally_to_rlds',
 'austin_sirius_dataset_converted_externally_to_rlds',
 'bair_robot_pushing_small',
 'bc_z',
 'bccd',
```

```
'beans',
'bee_dataset',
'beir',
'berkeley_autolab_ur5',
'berkeley_cable_routing',
'berkeley_fanuc_manipulation',
'berkeley_gnm_cory_hall',
'berkeley_gnm_recon',
'berkeley_gnm_sac_son',
'berkeley_mvp_converted_externally_to_rlds',
'berkeley_rpt_converted_externally_to_rlds',
'big_patent',
'bigearthnet',
'billsum',
'binarized_mnist',
'binary_alpha_digits',
'ble_wind_field',
'blimp',
'booksum',
'bool_q',
'bot_adversarial_dialogue',
'bridge',
'bridge_data_msr',
'bucc',
'c4',
'c4_wsrs',
'caltech101',
'caltech_birds2010',
'caltech_birds2011',
'cardiotox',
'cars196',
'cassava',
'cats_vs_dogs',
'celeb_a',
'celeb_a_hq',
'cfq',
'cherry_blossoms',
'chexpert',
'cifar10',
'cifar100',
'cifar100_n',
'cifar10_1',
'cifar10_corrupted',
'cifar10_h',
'cifar10_n',
'citrus_leaves',
'cityscapes',
'civil_comments',
'clevr',
```

```
'clic',
'clinc_oos',
'cmaterdb',
'cmu_franka_exploration_dataset_converted_externally_to_rlds',
'cmu_play_fusion',
'cmu_stretch',
'cnn_dailymail',
'coco',
'coco_captions',
'coil100',
'colorectal_histology',
'colorectal_histology_large',
'columbia_cairlab_pusht_real',
'common_voice',
'conll2002',
'conll2003',
'conq_hose_manipulation',
'controlled_noisy_web_labels',
'coqa',
'corr2cause',
'cos_e',
'cosmos_qa',
'covid19',
'covid19sum',
'crema_d',
'criteo',
'cs_restaurants',
'curated_breast_imaging_ddsm',
'cycle_gan',
'd4rl_adroit_door',
'd4rl_adroit_hammer',
'd4rl_adroit_pen',
'd4rl_adroit_relocate',
'd4rl_antmaze',
'd4rl_mujoco_ant',
'd4rl_mujoco_halfcheetah',
'd4rl_mujoco_hopper',
'd4rl_mujoco_walker2d',
'dart',
'databricks_dolly',
'davis',
'deep1b',
'deep_weeds',
'definite_pronoun_resolution',
'dementiabank',
'diabetic_retinopathy_detection',
'diamonds',
'dices',
'div2k',
```

```
'dlr_edan_shared_control_converted_externally_to_rlds',
'dlr_sara_grid_clamp_converted_externally_to_rlds',
'dlr_sara_pour_converted_externally_to_rlds',
'dmlab',
'dobbe',
'doc_nli',
'dolphin_number_word',
'domainnet',
'downscaled_imagenet',
'drop',
'dsprites',
'dtd',
'duke_ultrasound',
'e2e_cleaned',
'efron_morris75',
'emnist',
'eraser_multi_rc',
'esnli',
'eth_agent_affordances',
'eurosat',
'fashion_mnist',
'flic',
'flores',
'fmb',
'food101',
'forest_fires',
'fractal20220817_data',
'fuss',
'gap',
'geirhos_conflict_stimuli',
'gem',
'genomics_ood',
'german_credit_numeric',
'gigaword',
'glove100-angular',
'glue',
'goemotions',
'gov_report',
'gpt3',
'gref',
'groove',
'grounded_scan',
'gsm8k',
'gtzan',
'gtzan_music_speech',
'hellaswag',
'higgs',
'hillstrom',
'horses_or_humans',
```

```
'howell',
'i_naturalist2017',
'i_naturalist2018',
'i_naturalist2021',
'iamlab_cmu_pickup_insert_converted_externally_to_rlds',
'imagenet2012',
'imagenet2012_corrupted',
'imagenet2012_fewshot',
'imagenet2012_multilabel',
'imagenet2012_real',
'imagenet2012_subset',
'imagenet_a',
'imagenet_lt',
'imagenet_pi',
'imagenet_r',
'imagenet_resized',
'imagenet_sketch',
'imagenet_v2',
'imagenette',
'imagewang',
'imdb_reviews',
'imperialcollege_sawyer_wrist_cam',
'io_ai_tech',
'irc_disentanglement',
'iris',
'istella',
'jaco_play',
'kaist_nonprehensile_converted_externally_to_rlds',
'kddcup99',
'kitti',
'kmnist',
'kuka',
'laion400m',
'lambada',
'lfw',
'librispeech',
'librispeech_lm',
'libritts',
'ljspeech',
'lm1b',
'locomotion',
'lost_and_found',
'lsun',
'lvis',
'malaria',
'maniskill_dataset_converted_externally_to_rlds',
'math_dataset',
'math_qa',
'mctaco',
```

```
'media_sum',
'mimic_play',
'mlqa',
'mnist',
'mnist_corrupted',
'movie_lens',
'movie rationales',
'movielens',
'moving_mnist',
'mrqa',
'mslr_web',
'mt_opt',
'mtnl',
'multi_news',
'multi_nli',
'multi_nli_mismatch',
'natural_instructions',
'natural_questions',
'natural_questions_open',
'newsroom',
'nsynth',
'nyu_depth_v2',
'nyu_door_opening_surprising_effectiveness',
'nyu_franka_play_dataset_converted_externally_to_rlds',
'nyu_rot_dataset_converted_externally_to_rlds',
'ogbg_molpcba',
'omniglot',
'open_images_challenge2019_detection',
'open_images_v4',
'openbookqa',
'opinion_abstracts',
'opinosis',
'opus',
'oxford_flowers102',
'oxford_iit_pet',
'para_crawl',
'pass',
'patch_camelyon',
'paws_wiki',
'paws_x_wiki',
'penguins',
'pet_finder',
'pg19',
'piqa',
'places365_small',
'placesfull',
'plant_leaves',
'plant_village',
'plantaek',
```

```
'plex_robosuite',
'protein_net',
'q_re_cc',
'qa4mre',
'qasc',
'qm9',
'quac',
'quality',
'quickdraw_bitmap',
'race',
'radon',
'real_toxicity_prompts',
'reddit',
'reddit_disentanglement',
'reddit_tifu',
'ref_coco',
'resisc45',
'rlu_atari',
'rlu_atari_checkpoints',
'rlu_atari_checkpoints_ordered',
'rlu_control_suite',
'rlu_dmlab_explore_object_rewards_few',
'rlu_dmlab_explore_object_rewards_many',
'rlu_dmlab_rooms_select_nonmatching_object',
'rlu_dmlab_rooms_watermaze',
'rlu_dmlab_seekavoid_arena01',
'rlu_locomotion',
'rlu_rwrl',
'robo_set',
'robomimic_mg',
'robomimic_mh',
'robomimic_ph',
'robonet',
'robosuite_panda_pick_place_can',
'roboturk',
'rock_paper_scissors',
'rock_you',
's3o4d',
'salient_span_wikipedia',
'samsung',
'savee',
'scan',
'scene_parse150',
'schema_guided_dialogue',
'sci_tail',
'scicite',
'scientific_papers',
'scrolls',
'segment_anything',
```

```
'sentiment140',
'shapes3d',
'sift1m',
'simpTe',
'siscore',
'smallnorb',
'smartwatch_gestures',
'snli',
'so2sat',
'speech_commands',
'spoc_robot',
'spoken_digit',
'squad',
'squad_question_generation',
'stanford_dogs',
'stanford_hydra_datasetConvertedExternallyToRlds',
'stanford_kuka_multimodal_datasetConvertedExternallyToRlds',
'stanford_mask_vitConvertedExternallyToRlds',
'stanford_online_products',
'stanford_robocookConvertedExternallyToRlds',
'star_cfq',
'starcraft_video',
'stl10',
'story_cloze',
'summscreen',
'sun397',
'super_glue',
'svhn_cropped',
'symmetric_solids',
'taco_play',
'tao',
'tatoeba',
'ted_hrlr_translate',
'ted_multi_translate',
'tedlium',
'tf_flowers',
'the300w_lp',
'tidybot',
'tiny_shakespeare',
'titanic',
'tokyo_u_lsmoConvertedExternallyToRlds',
'toto',
'trec',
'trivia_qa',
'tydi_qa',
'uc_merced',
'ucf101',
'ucsd_kitchen_datasetConvertedExternallyToRlds',
'ucsd_pick_and_place_datasetConvertedExternallyToRlds',
```

```
'uiuc_d3field',
'unified_qa',
'universal_dependencies',
'unnatural_instructions',
'usc_cloth_simConvertedExternallyToRlds',
'user_libri_audio',
'user_libri_text',
'utaustin_mutex',
'utokyo_pr2_opening_fridgeConvertedExternallyToRlds',
'utokyo_pr2_tabletop_manipulationConvertedExternallyToRlds',
'utokyo_saytap_ConvertedExternallyToRlds',
'utokyo_xarm_bimanualConvertedExternallyToRlds',
'utokyo_xarm_pick_and_placeConvertedExternallyToRlds',
'vectk',
'vema_ConvertedExternallyToRlds',
'viola',
'vesual_domain_decathlon',
'veoc',
'veoxceleb',
'vexforge',
'veyamo_open_dataset',
'veb_graph',
'veb_nlg',
'veb_questions',
'vebvid',
'veder_face',
'veki40b',
'veki_auto',
'veki_bio',
'veki_dialog',
'veki_table_questions',
'veki_table_text',
'vekiann',
'vekihow',
'vekipedia',
'vekipedia_toxicity_subtypes',
'veine_quality',
'veinogrande',
'veit',
'veit_kaggle',
'vemt13_translate',
'vemt14_translate',
'vemt15_translate',
'vemt16_translate',
'vemt17_translate',
'vemt18_translate',
'vemt19_translate',
'vemt_t2t_translate',
'vemt_translate',
```

```

'wordnet',
'wsc273',
'xnli',
'xquad',
'xsum',
'xtreme_pawsx',
'xtreme_pos',
'xtreme_s',
'xtreme_xnli',
'yahoo_ltrc',
'yelp_polarity_reviews',
'yes_no',
'youtube_vis']

# Vérifiez si food101 est dans la liste des datasets
print("food101" in tfds_list)

```

True

Chargement des données (prend environ 5 - 6 minutes)

```

(train_data, test_data), ds_info = tfds.load(
    name="food101",
    split=["train", "validation"],
    shuffle_files=True,
    as_supervised=True, # Les données seront retournées sous forme de
tuple (données, étiquette)
    with_info=True # Donne des métadonnées (ds_info)
)

```

Remarque : Si le dataset a déjà été téléchargé, le code précédent ne le téléchargera pas à nouveau.

Caractéristiques de food101

```

ds_info.features

FeaturesDict({
    'image': Image(shape=(None, None, 3), dtype=uint8),
    'label': ClassLabel(shape=(), dtype=int64, num_classes=101),
})

# Obtenir les noms des classes
class_names = ds_info.features["label"].names
# Affiche les 10 premiers aliments du dataset
class_names[:10]

['apple_pie',
 'baby_back_ribs',
 'baklava',
 'beef_carpaccio',
 'beef_tartare',

```

```
'beet_salad',
'beignets',
'bibimbap',
'bread_pudding',
'breakfast_burrito']
```

### Explorer le dataset Food

- Noms des classes
- Forme de notre entrée (tenseurs d'images)
- Le type de données de nos entrées
- À quoi ressemblent les étiquettes ? (sont-elles encodées en one-hot ou label encoded)
- Les étiquettes correspondent-elles aux noms des classes ?

### Prendre un échantillon des données d'entraînement

```
train_one_simple = train_data.take(1)

train_one_simple # Les échantillons sont au format format (image
# et label)

<_TakeDataset element_spec=(TensorSpec(shape=(None, None, 3),
dtype=tf.uint8, name=None), TensorSpec(shape=(), dtype=tf.int64,
name=None))>

# Afficher des informations sur notre échantillon d'entraînement
for image, label in train_one_simple:
    print(f"""
    Image shape : {image.shape}
    Image datatype : {image.dtype}
    Target class : {label}
    Class names string form : {class_names[label.numpy()]}
    """)

    Image shape : (384, 512, 3)
    Image datatype : <dtype: 'uint8'>
    Target class : 70
    Class names string form : pad_thai
```

```
# À quoi ressemble notre tenseur d'image ?
image
```

```
<tf.Tensor: shape=(384, 512, 3), dtype=uint8, numpy=
array([[230, 229, 183],
       [231, 230, 184],
       [232, 231, 183],
       ...,
       [232, 233, 202],
       [229, 234, 204],
```

```
[229, 236, 205]],  
[[228, 227, 179],  
[227, 226, 178],  
[226, 226, 176],  
...,  
[234, 235, 204],  
[232, 237, 207],  
[234, 241, 210]],  
  
[[229, 229, 175],  
[229, 229, 175],  
[227, 227, 175],  
...,  
[233, 234, 202],  
[232, 237, 205],  
[235, 242, 209]],  
  
...,  
[[119, 97, 58],  
[131, 109, 70],  
[131, 109, 70],  
...,  
[239, 241, 220],  
[238, 240, 219],  
[238, 240, 219]],  
  
[[120, 98, 61],  
[133, 111, 74],  
[135, 113, 76],  
...,  
[240, 242, 221],  
[240, 242, 221],  
[240, 242, 221]],  
  
[[136, 114, 77],  
[135, 113, 76],  
[129, 107, 70],  
...,  
[243, 245, 224],  
[244, 246, 225],  
[245, 247, 226]]], dtype=uint8)>  
  
# Quelles sont les valeurs minimales et maximales de l'image, censées  
être entre 0 et 255 ?  
import tensorflow as tf  
tf.reduce_min(image), tf.reduce_max(image)
```

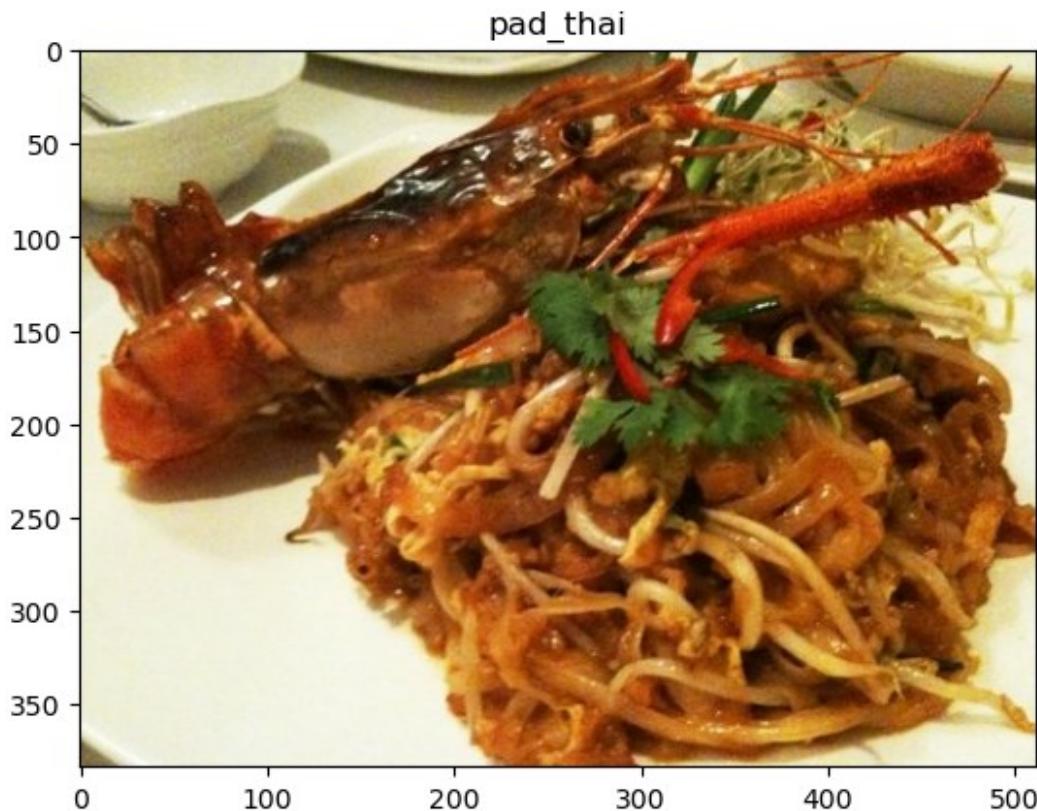
```
(<tf.Tensor: shape=(), dtype=uint8, numpy=0>,
 <tf.Tensor: shape=(), dtype=uint8, numpy=255>)
```

Neural networks like images to be encoded between 0 and 1

```
# Afficher une image du dataset TensorFlow
import matplotlib.pyplot as plt

plt.imshow(image)
plt.title(class_names[label.numpy()])

Text(0.5, 1.0, 'pad_thai')
```



Créer des fonctions de prétraitement pour nos données

Ce que nous savons sur nos données :

- Type de données 'uint8'
- Composé de tailles variées de tenseurs (images de tailles différentes)
- Non mises à l'échelle (les valeurs des pixels sont comprises entre 0 et 255)
- Ce que nous savons sur les modèles :

Données en 'float32'

- TensorFlow préfère que toutes les images d'un lot aient la même taille
- Mises à l'échelle (valeurs entre 0 et 1, également appelé normalisé)

- Avec cela en tête, nous avons plusieurs choses à aborder avec une fonction de prétraitement.

Comme nous allons utiliser EfficientNetBX pré-entraîné de tf.keras.applications, nous n'avons pas besoin de redimensionner nos données (ces architectures ont un redimensionnement intégré).

Notre fonction doit :

- Redimensionner toutes nos images à la même taille
- Convertir le type de données de nos tenseurs d'image de 'uint8' à 'float32'

```
# Créer une fonction pour le prétraitement des images
def preprocess_img(image, label, img_shape=244):
    """
    Convertir le type de données de l'image de 'uint8' à 'float32' et
    redimensionner l'image à (img_shape, img_shape, 3).
    """
    image = tf.image.resize(image, [img_shape, img_shape]) # Reshape
    target image
    return tf.cast(image, tf.float32), label

# Prétraiter une seule image échantillon et vérifier le résultat
preprocessed_img = preprocess_img(image, label)[0] # retourne un tuple
et nous voulons seulement l'image
print(f"Image before preprocessing:\n {image[:2]}")
print(f"Image shape: {image.shape}")
print(f"Image dtype: {image.dtype}")
print(f"#####")
print(f"Image after preprocessing:\n {preprocessed_img[:2]}")
print(f"Image shape: {preprocessed_img.shape}")
print(f"Image dtype: {preprocessed_img.dtype}")

Image before preprocessing:
[[[230 229 183]
 [231 230 184]
 [232 231 183]
 ...
 [232 233 202]
 [229 234 204]
 [229 236 205]]]

[[[228 227 179]
 [227 226 178]
 [226 226 176]
 ...
 [234 235 204]
 [232 237 207]
 [234 241 210]]]

Image shape: (384, 512, 3)
Image dtype: <dtype: 'uint8'>
#####
Image after preprocessing:
```

```

[[[229.66031 228.66031 182.08653]
 [230.00269 229.28958 180.7158 ]
 [224.9142 224.9142 173.4224 ]

 ...
 [237.75494 231.47707 201.58101]
 [235.6259 233.38799 203.68315]
 [230.11931 236.02092 205.57011]]

[[228.78413 228.64479 175.48085]
 [226.39359 226.39359 174.67227]
 [227.06 227.06 175.1308 ]

 ...
 [237.92068 232.17474 200.24554]
 [235.17233 233.49176 202.36893]
 [233.2896 239.19121 207.01909]]]

Image shape: (244, 244, 3)
Image dtype: <dtype: 'float32'>

```

Batcher et préparer les datasets

Nous allons maintenant rendre notre pipeline d'entrée de données vraiment rapide.

```

# Mapper la fonction de prétraitement sur les données d'entraînement
(AUTOTUNE utilise autant de processus que possible)
# Prétraiter et batcher les données d'entraînement
train_data = train_data.map(lambda x, y: preprocess_img(x, y,
img_shape=224), num_parallel_calls=tf.data.AUTOTUNE)
train_data =
train_data.shuffle(buffer_size=1000).batch(batch_size=32).prefetch(tf.
data.AUTOTUNE)

# Prétraiter et batcher les données de test
test_data = test_data.map(lambda x, y: preprocess_img(x, y,
img_shape=224), num_parallel_calls=tf.data.AUTOTUNE)
test_data = test_data.batch(batch_size=32).prefetch(tf.data.AUTOTUNE)

train_data, test_data

(<_PrefetchDataset element_spec=(TensorSpec(shape=(None, 224, 224, 3),
dtype=tf.float32, name=None), TensorSpec(shape=(None,), 
dtype=tf.int64, name=None))>,
 <_PrefetchDataset element_spec=(TensorSpec(shape=(None, 224, 224, 3),
dtype=tf.float32, name=None), TensorSpec(shape=(None,), 
dtype=tf.int64, name=None))>)

```

Créer des callbacks pour le modèle

Nous allons créer plusieurs callbacks pour nous aider pendant l'entraînement du modèle :

- Callback TensorBoard pour enregistrer les résultats de l'entraînement (pour que nous puissions les visualiser plus tard si nécessaire)

- Callback ModelCheckpoint pour sauvegarder la progression de notre modèle après l'extraction des caractéristiques

```
# Créer le callback TensorBoard (importé depuis helper_functions.py)
from helper_functions import create_tensorboard_callback

# Sauvegarder les poids au lieu de sauvegarder tout le modèle, ce qui
# est plus rapide
checkpoint_path = "model_checkpoints/cp.weights.h5"
model_checkpoint = tf.keras.callbacks.ModelCheckpoint(checkpoint_path,

monitor="val_acc",
save_best_only=True,
save_weights_only=True,
verbose=0)
# verbose = 0, ne rien afficher si le modèle est sauvegardé ou non
```

## Configurer l'entraînement en précision mixte

```
# Activer l'entraînement en précision mixte
from tensorflow.keras import mixed_precision
mixed_precision.set_global_policy("mixed_float16") # Définir la
# politique de données globale en précision mixte
# Utiliser les types de données float16 et float32 pour accélérer les
# performances du modèle

mixed_precision.global_policy()

<FloatDTypePolicy "mixed_float16">
```

## Construire un modèle d'extraction de caractéristiques

```
len(class_names)
101
from tensorflow.keras import layers

# Créer le modèle de base
input_shape = (224, 224, 3)
base_model = tf.keras.applications.EfficientNetV2B0(include_top=False)
# Geler les poids des paramètres du modèle de base
base_model.trainable = False

# Créer un modèle fonctionnel
inputs = layers.Input(shape=input_shape, name="input_layer")

x = base_model(inputs, training=False)
x = layers.GlobalAveragePooling2D()(x)
```

```

x = layers.Dense(len(class_names))(x)
outputs = layers.Activation("softmax", dtype=tf.float32,
name="softmax_float32")(x)

model = tf.keras.Model(inputs, outputs)

# Compiler le modèle
model.compile(loss="sparse_categorical_crossentropy",
optimizer=tf.keras.optimizers.Adam(), metrics=["accuracy"])

model.summary()

```

Model: "functional\_1"

Layer (type)	Output Shape
Param #	
input_layer (InputLayer)	(None, 224, 224, 3)
0	
efficientnetv2-b0 (Functional)	(None, 7, 7, 1280)
5,919,312	
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)
0	
dense (Dense)	(None, 101)
129,381	
softmax_float32 (Activation)	(None, 101)
0	

Total params: 6,048,693 (23.07 MB)

Trainable params: 129,381 (505.39 KB)

Non-trainable params: 5,919,312 (22.58 MB)

Vérifier les politiques dtype des couches : utilisons-nous la précision mixte ?

```
# Vérifier les attributs dtype_policy des couches de notre modèle
for layer in model.layers:
    print(layer.name, layer.trainable, layer.dtype,
layer.dtype_policy)

input_layer True float32 <FloatDTypePolicy "mixed_float16">
efficientnetv2-b0 False float32 <FloatDTypePolicy "mixed_float16">
global_average_pooling2d True float32 <FloatDTypePolicy
"mixed_float16">
dense True float32 <FloatDTypePolicy "mixed_float16">
softmax_float32 True float32 <FloatDTypePolicy "float32">

# Vérifier les attributs dtype_policy des couches du modèle
EfficientV2NetB0
for layer in base_model.layers:
    print(layer.name, layer.trainable, layer.dtype,
layer.dtype_policy)

input_layer False float32 <FloatDTypePolicy "mixed_float16">
rescaling False float32 <FloatDTypePolicy "mixed_float16">
normalization False float32 <FloatDTypePolicy "mixed_float16">
stem_conv False float32 <FloatDTypePolicy "mixed_float16">
stem_bn False float32 <FloatDTypePolicy "mixed_float16">
stem_activation False float32 <FloatDTypePolicy "mixed_float16">
block1a_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block1a_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block1a_project_activation False float32 <FloatDTypePolicy
"mixed_float16">
block2a_expand_conv False float32 <FloatDTypePolicy "mixed_float16">
block2a_expand_bn False float32 <FloatDTypePolicy "mixed_float16">
block2a_expand_activation False float32 <FloatDTypePolicy
"mixed_float16">
block2a_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block2a_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block2b_expand_conv False float32 <FloatDTypePolicy "mixed_float16">
block2b_expand_bn False float32 <FloatDTypePolicy "mixed_float16">
block2b_expand_activation False float32 <FloatDTypePolicy
"mixed_float16">
block2b_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block2b_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block2b_drop False float32 <FloatDTypePolicy "mixed_float16">
block2b_add False float32 <FloatDTypePolicy "mixed_float16">
block3a_expand_conv False float32 <FloatDTypePolicy "mixed_float16">
block3a_expand_bn False float32 <FloatDTypePolicy "mixed_float16">
block3a_expand_activation False float32 <FloatDTypePolicy
"mixed_float16">
block3a_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block3a_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block3b_expand_conv False float32 <FloatDTypePolicy "mixed_float16">
```











```

block6h_dwconv2 False float32 <FloatDTypePolicy "mixed_float16">
block6h_bn False float32 <FloatDTypePolicy "mixed_float16">
block6h_activation False float32 <FloatDTypePolicy "mixed_float16">
block6h_se_squeeze False float32 <FloatDTypePolicy "mixed_float16">
block6h_se_reshape False float32 <FloatDTypePolicy "mixed_float16">
block6h_se_reduce False float32 <FloatDTypePolicy "mixed_float16">
block6h_se_expand False float32 <FloatDTypePolicy "mixed_float16">
block6h_se_excite False float32 <FloatDTypePolicy "mixed_float16">
block6h_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block6h_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block6h_drop False float32 <FloatDTypePolicy "mixed_float16">
block6h_add False float32 <FloatDTypePolicy "mixed_float16">
top_conv False float32 <FloatDTypePolicy "mixed_float16">
top_bn False float32 <FloatDTypePolicy "mixed_float16">
top_activation False float32 <FloatDTypePolicy "mixed_float16">

mixed_precision.global_policy()

<FloatDTypePolicy "mixed_float16">

```

Entraîner le modèle d'extraction de caractéristiques

```

# Entrainer le modèle d'extraction de caractéristiques avec des
# callbacks
history_101_food_classes_feature_extract = model.fit(train_data,
                                                       epochs=3,
                                                       steps_per_epoch=len(train_data),
                                                       validation_data=test_data,
                                                       validation_steps=int(0.15 * len(test_data)),
                                                       callbacks=[create_tensorboard_callback(dir_name="training_logs",
                                                       experiment_name="efficientnetb0_101_classes_all_data_feature_extract"),
                                                       model_checkpoint])

Saving TensorBoard log files to:
training_logs/efficientnetb0_101_classes_all_data_feature_extract/
20241003-090308
Epoch 1/3
2368/2368 ━━━━━━━━━━ 3742s 2s/step - accuracy: 0.4600 - loss: 2.3543 - val_accuracy: 0.6962 - val_loss: 1.1668
Epoch 2/3

C:\Users\anasa\AppData\Roaming\jupyterlab-desktop\jlab_server\Lib\
site-packages\keras\src\callbacks\model_checkpoint.py:206:
UserWarning: Can save best model only with val_acc available,

```

```
skipping.
    self._save_model(epoch=epoch, batch=None, logs=logs)
C:\Users\anasa\AppData\Roaming\jupyterlab-desktop\jlab_server\Lib\
contextlib.py:158: UserWarning: Your input ran out of data;
interrupting training. Make sure that your dataset or generator can
generate at least `steps_per_epoch * epochs` batches. You may need to
use the `repeat()` function when building your dataset.
    self.gen.throw(value)

2368/2368 ━━━━━━━━ 168s 71ms/step - accuracy: 0.0000e+00 -
loss: 0.0000e+00 - val_accuracy: 0.6841 - val_loss: 1.1820
Epoch 3/3
2368/2368 ━━━━━━━━ 3672s 2s/step - accuracy: 0.6586 -
loss: 1.3329 - val_accuracy: 0.7142 - val_loss: 1.0480

# Évaluer le modèle sur l'ensemble du dataset de test
results_feature_extract_model = model.evaluate(test_data)
results_feature_extract_model

790/790 ━━━━━━━━ 1159s 1s/step - accuracy: 0.7168 - loss:
1.0524

[1.0519026517868042, 0.7169108986854553]

# Sauvegarder le modèle localement (si vous utilisez Google Colab, le
modèle sauvegardé sera supprimé lorsque l'instance Colab sera
terminée)
save_dir =
"07_efficientnetb0_feature_extract_model_mixed_precision.keras"
model.save(save_dir)

# Charger le modèle précédemment sauvegardé
loaded_saved_model = tf.keras.models.load_model(save_dir)

# Vérifier les couches du modèle de base et voir quelle politique
dtype elles utilisent
for layer in loaded_saved_model.layers[1].layers[:20]: # vérifier
uniquement les 20 premières couches pour limiter la sortie
    print(layer.name, layer.trainable, layer.dtype,
layer.dtype_policy)

input_layer True float32 <FloatDTypePolicy "mixed_float16">
rescaling False float32 <FloatDTypePolicy "mixed_float16">
normalization False float32 <FloatDTypePolicy "mixed_float16">
stem_conv False float32 <FloatDTypePolicy "mixed_float16">
stem_bn False float32 <FloatDTypePolicy "mixed_float16">
stem_activation False float32 <FloatDTypePolicy "mixed_float16">
block1a_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block1a_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block1a_project_activation False float32 <FloatDTypePolicy
"mixed_float16">
```

```

block2a_expand_conv False float32 <FloatDTypePolicy "mixed_float16">
block2a_expand_bn False float32 <FloatDTypePolicy "mixed_float16">
block2a_expand_activation False float32 <FloatDTypePolicy
"mixed_float16">
block2a_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block2a_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block2b_expand_conv False float32 <FloatDTypePolicy "mixed_float16">
block2b_expand_bn False float32 <FloatDTypePolicy "mixed_float16">
block2b_expand_activation False float32 <FloatDTypePolicy
"mixed_float16">
block2b_project_conv False float32 <FloatDTypePolicy "mixed_float16">
block2b_project_bn False float32 <FloatDTypePolicy "mixed_float16">
block2b_drop False float32 <FloatDTypePolicy "mixed_float16">

# Vérifier les performances du modèle chargé (cela devrait être les
# mêmes que celles du modèle d'extraction de caractéristiques)
results_loaded_saved_model = loaded_saved_model.evaluate(test_data)
results_loaded_saved_model

790/790 ━━━━━━━━━━━━ 1169s 1s/step - accuracy: 0.7166 - loss:
1.0528

[1.0519040822982788, 0.7169108986854553]

# Les résultats du modèle chargé doivent être égaux (ou du moins très
# proches) de ceux du modèle avant la sauvegarde
# Remarque : cela ne fonctionnera que si vous avez instancié des
# variables de résultats
# import numpy as np
# assert np.isclose(results_feature_extract_model,
# results_loaded_saved_model, rtol=1e-05, atol=1e-08).all()

# Obtenir un résumé de notre modèle téléchargé
loaded_saved_model.summary()

Model: "functional_1"


```

Layer (type)	Output Shape
Param #	
input_layer (InputLayer)	(None, 224, 224, 3)
0	
efficientnetv2-b0 (Functional)	(None, 7, 7, 1280)
5,919,312	

```

global_average_pooling2d | (None, 1280) |
0 | (GlobalAveragePooling2D) |
|-----|
| dense (Dense) | (None, 101) |
129,381 |
|-----|
| softmax_float32 (Activation) | (None, 101) |
0 |
|-----|
Total params: 6,307,461 (24.06 MB)
Trainable params: 129,381 (505.39 KB)
Non-trainable params: 5,919,312 (22.58 MB)
Optimizer params: 258,768 (1010.82 KB)

# Configurer le callback EarlyStopping pour arrêter l'entraînement si la val_loss du modèle n'améliore pas pendant 3 époques
early_stopping = tf.keras.callbacks.EarlyStopping(monitor="val_loss",
# Surveiller la métrique val_loss
                                         patience=3) # Si la val_loss diminue pendant 3 époques d'affilée, arrêter l'entraînement

# Créer un callback ModelCheckpoint pour sauvegarder le meilleur modèle pendant le fine-tuning
checkpoint_path = "fine_tune_checkpoints/fine_tune_checkpoints.keras"
model_checkpoint = tf.keras.callbacks.ModelCheckpoint(checkpoint_path,
save_best_only=True,
monitor="val_loss")

# Créer un callback de réduction du taux d'apprentissage
reduce_lr = tf.keras.callbacks.ReduceLROnPlateau(monitor="val_loss",
                                                 factor=0.2, # multiply the learning rate by 0.2 (reduce by 5x)
                                                 patience=2,
                                                 verbose=1, # print
                                                 min_lr=1e-7)

# Compiler le modèle
loaded_saved_model.compile(loss="sparse_categorical_crossentropy", # sparse_categorical_crossentropy car les labels ne sont pas one-hot

```

```

        optimizer=tf.keras.optimizers.Adam(0.0001),  #
10x moins que le taux d'apprentissage par défaut
        metrics=["accuracy"])

# Commencer le fine-tuning (pour toutes les couches)
history_101_food_classes_all_data_fine_tune =
loaded_saved_model.fit(train_data,
epoch=100, # Affiner pour un maximum de 100 époques

steps_per_epoch=len(train_data),
validation_data=test_data,
validation_steps=int(0.15 * len(test_data)), # Validation pendant
l'entraînement sur 15% des données de test

callbacks=[create_tensorboard_callback("training_logs",
"efficientb0_101_classes_all_data_fine_tuning"), # Garder trace des
logs du modèle pendant l'entraînement

model_checkpoint, # Sauvegarder uniquement le meilleur modèle pendant
l'entraînement

early_stopping, # Arrêter le modèle après X époques sans améliorations

reduce_lr]) # Réduire le taux d'apprentissage après X époques sans
améliorations

Saving TensorBoard log files to:
training_logs/efficientb0_101_classes_all_data_fine_tuning/20241003-
114824
Epoch 1/100
2368/2368 ━━━━━━━━ 3656s 2s/step - accuracy: 0.7011 -
loss: 1.1496 - val_accuracy: 0.7381 - val_loss: 1.0137 -
learning_rate: 1.0000e-04
Epoch 2/100
2368/2368 ━━━━━━━━ 167s 71ms/step - accuracy: 0.0000e+00 -
loss: 0.0000e+00 - val_accuracy: 0.7256 - val_loss: 1.0239 -
learning_rate: 1.0000e-04
Epoch 3/100
2368/2368 ━━━━━━━━ 3800s 2s/step - accuracy: 0.7087 -
loss: 1.1279 - val_accuracy: 0.7336 - val_loss: 0.9921 -
learning_rate: 1.0000e-04
Epoch 4/100
2368/2368 ━━━━━━━━ 181s 76ms/step - accuracy: 0.0000e+00 -
loss: 0.0000e+00 - val_accuracy: 0.7370 - val_loss: 0.9848 -
learning_rate: 1.0000e-04
Epoch 5/100
2368/2368 ━━━━━━━━ 3849s 2s/step - accuracy: 0.7141 -

```

```

loss: 1.1101 - val_accuracy: 0.7264 - val_loss: 0.9995 -
learning_rate: 1.0000e-04
Epoch 6/100

Epoch 6: ReduceLROnPlateau reducing learning rate to
1.999999494757503e-05.
2368/2368 ━━━━━━━━ 196s 83ms/step - accuracy: 0.0000e+00 -
loss: 0.0000e+00 - val_accuracy: 0.7301 - val_loss: 1.0164 -
learning_rate: 1.0000e-04
Epoch 7/100
2368/2368 ━━━━━━━━ 3689s 2s/step - accuracy: 0.7208 -
loss: 1.0872 - val_accuracy: 0.7263 - val_loss: 1.0203 -
learning_rate: 2.0000e-05

# Sauvegarder le modèle localement
loaded_saved_model.save("07_efficientnetb0_fine_tuned_101_classes_mixed_precision.keras")

# Charger le modèle fine-tuné depuis Google Storage et évaluer
loaded_fine_tuned_gs_model =
tf.keras.models.load_model("07_efficientnetb0_fine_tuned_101_classes_mixed_precision.keras")

# Obtenir un résumé du modèle (même architecture que ci-dessus)
loaded_fine_tuned_gs_model.summary()

Model: "functional_1"

```

Layer (type)	Output Shape
Param #	
input_layer (InputLayer)	(None, 224, 224, 3)
0	
efficientnetv2-b0 (Functional)	(None, 7, 7, 1280)
5,919,312	
global_average_pooling2d	(None, 1280)
0 (GlobalAveragePooling2D)	
dense (Dense)	(None, 101)
129,381	

softmax_float32 (Activation)	(None, 101)
0	

Total params: 6,307,461 (24.06 MB)

Trainable params: 129,381 (505.39 KB)

Non-trainable params: 5,919,312 (22.58 MB)

Optimizer params: 258,768 (1010.82 KB)

```
results_downloaded_fine_tuned_gs_model =  
loaded_fine_tuned_gs_model.evaluate(test_data)  
results_downloaded_fine_tuned_gs_model
```

790/790 ————— 1214s 2s/step - accuracy: 0.7362 - loss:  
0.9983

[0.9974470138549805, 0.7340593934059143]